

FET445 Veri Madencilği

Amazon Ürün Yorumlarına Dayalı Metin Sınıflandırması

ÖĞRETİM ÜYESİ: Dr. Yıldız Karadayı

Group: Semicolon

Ad - Soyad	Öğrenci No
Gays Harmuş	22040301144
Ahmed Asfour	22040301084
Elisa Demir	22040301152
Ayham Elmatar	22040301011
BiBi Sanam Faizi	22040301086

HAZIRLAYAN : AHMED ASFOUR

<https://github.com/evil1341/Semicolon>

<https://youtu.be/QcDXZdtB5j0>



Tarih: 08.01.2026

Amazon Ürün Yorumlarına Dayalı Metin Sınıflandırması

Amazon ürün yorumlarını kullanarak kullanıcı memnuniyetini metin tabanlı bir sınıflandırma problemi olarak ele aldığımız projemizi sunacağız.



CONTENTS

01.

Problem Definition

Amazon Ürün Yorumlarının Sınıflandırılması

02.

Dataset Description

Amazon All Beauty Reviews Veri Seti

03.

Feature Engineering & Modeling

Metin Tabanlı Özellik Çıkarımı ve Modeller

04.

Sonuç ve Değerlendirme



PROBLEM DEFINITION



Online alışveriş platformlarında kullanıcıların ilgilenebileceği ürünleri doğru şekilde önermek kritik bir problemdir.

Yanlış veya alakasız öneriler kullanıcı memnuniyetini ve satış performansını olumsuz etkiler.

Bu projede, kullanıcı-ürün etkileşimleri kullanılarak ürün puanı tahmini yapılmış ve öneri sistemi geliştirilmiştir.

Farklı makine öğrenmesi yaklaşımlarının performansları karşılaştırılmıştır.

Amaç:

Gerçek dünya verisi üzerinde öneri sistemleri geliştirmek ve farklı model yaklaşımlarını karşılaştırmak.



Veri Seti Detayları

Amazon All Beauty Reviews Veri Seti



01

Kaynak: Amazon All Beauty Review

Gözlem sayısı: ~600.000+ yorum

02

Veri türleri:

- Metin: kullanıcı yorumu (review text)
 - Sayısal: rating (1-5)
-

03

Kullanılan temel sütunlar:

Asin + text + rating

Dataset Description



projede Amazon All Beauty ürün yorumları veri seti kullanılmıştır.

Veri seti kullanıcıların ürünler için verdiği puanları ve ürün kimlik bilgilerini içermektedir.

- Kullanıcı ID
- Ürün ID (ASIN)
- Rating (puan)

Yaklaşık **600.000+** kayıt içeren bu veri seti, gerçek dünya ve büyük ölçekli bir yapıya sahiptir.

Veri Seti linki

.....



Veri Ön İşleme



Ham veri doğrudan modele verilmemiş, çeşitli ön işleme adımlarından geçirilmiştir.

- Eksik değerler **"Unknown"** ile doldurulmuştur
- Kullanılamayan veya hatalı kayıtlar veri setinden çıkarılmıştır
- Veri seti eğitim ve test olarak ayrılmıştır
- Deneylerin tekrarlanabilirliği için **random_state = 42** kullanılmıştır



Baseline (Klasik) Modeller



Bu projede, öneri sisteminin temel performansını görmek amacıyla birden fazla **baseline (klasik) model** kullanılmıştır.

Bu modeller, projenin ana yapısını oluşturmakta ve daha karmaşık yaklaşımlar için temel oluşturmaktadır.

Projede Kullanılan Baseline Modeller:

- Naive Bayes
- K-Nearest Neighbors (KNN)
- Logistic Regression
- Decision Tree
- Linear SVM
- SGD Classifier

Bu modeller, kullanıcı-ürün etkileşimlerinden elde edilen veriler üzerinde aynı ön işleme adımları ve aynı veri bölünmesi kullanılarak uygulanmıştır.

Baseline Sonuç Değerlendirmesi:

- Baseline modeller arasında **en iyi performans** Logistic Regression ve KNN modellerinde gözlemlenmiştir.
- Bu modeller, basit yapıları sayesinde:
 - Daha kararlı sonuçlar üretmiş
 - Büyük ve seyrek veri setlerinde daha dengeli performans göstermiştir.



Gelişmiş Modeller



Baseline modellerin sınırlı temsil gücünü aşmak amacıyla projede gelişmiş makine öğrenmesi ve derin öğrenme tabanlı modeller kullanılmıştır. Bu modeller, kullanıcı-ürün etkileşimlerindeki karmaşık ilişkileri daha iyi öğrenebilmektedir.

Projede Kullanılan Gelişmiş Modeller:

- XGBoost *Classifier
- MLP Classifier
- Random Forest *Classifier
- Trees *Classifie
- CatBoost *Classifier

Projede Kullanılan Gelişmiş Modeller:

- Vector Machine (RBF Kernel)
- Autoencoder (Feature Extraction) + Classifier
- Multilayer Perceptron Classifier
- Gradient Boosting *Classifier
- Neural Network (PyTorch MLP)


•Gelişmiş Modellerin Genel Avantajları:

- Büyük ve seyrek veri setlerinde daha yüksek temsil gücü
- Doğrusal olmayan ilişkileri öğrenebilme
- Daha yüksek tahmin doğruluğu potansiyeli


modeller arasında **en iyi performans RANDOM FOREST (AHMED)** modellerinde gözlemlenmiştir.



Model Karşılaştırması (Baseline vs Gelişmiş)



Model Karşılaştırması (Baseline vs Gelişmiş)



projede, büyük ölçekli kullanıcı–ürün etkileşim verisi kullanılarak ürün puanı tahmini ve öneri sistemi geliştirilmiştir.

- Baseline modeller ile temel performans seviyesi belirlenmiştir.
- Gelişmiş modeller, doğrusal olmayan ilişkileri daha iyi öğrenmiştir.
- Regresyon tabanlı metrikler (MSE, MAE, R^2) ile değerlendirme yapılmıştır.
- Modeller arası karşılaştırma ile en uygun yaklaşım belirlenmiştir.

Sonuç olarak, gelişmiş modellerin genel olarak baseline modellere kıyasla daha yüksek tahmin başarımı sunduğu gözlemlenmiştir.



THANK YOU
FOR WATCHING

